

אותות אקראים

עבודה 1

מרצה: ד"ר יצחק לפידות

תאריך: 2.1.2020

מגיש:

יזיד בישאה 315914689

חלק 1

נבצע גנרציה של סדרה D באורך 1024 לשני גאוסיאנים G0, G1 באופן אקראי.

נעשה גנרציה לשבעה סדרות $k=0,1,\dots,6$

כל סדרה מחלקים ל-m סדרות אורך כל סדרה הוא 2^k
לפי התפלגות ברנולי קובעים מאיזה גאוסיאן.

פרמטרים של הגאוסיאן:

לפי תעודת זהות שלי 315914689

תעודת הזהות השנייה היא משותף בקורס 321194276 (בחרתי את המספר השני כדי שיהיה לנו שונות שונה מהגאוסיאן הרשואן)

$$\mu_0 = \frac{9}{10} = 0.9 \qquad \mu_1 = \frac{6}{10} = 0.6$$

$$\sigma_0^2 = \frac{3}{2} = 1.5 \qquad \sigma_1^2 = \frac{2}{2} = 1$$
$$G_0 \sim N(0.9, 1.5) \qquad G_1 \sim N(0.6, 1.5)$$

randn(m,n) : עושה גנרציה למטריצה בגודל m x n שהערכים שיש בה מתפלגים נורמלית

$$\forall i \cdot x_i \sim N(0,1)$$

כדי ליצור הפרמטרים הרצויים מכפילים כל איבר בשונות הרצויה ומוסיפים את התוחלת

$$y_i = x_i * \sigma + \mu$$

חלק 2

משערך ML

באמצעות משערך ML משעריכים את הסדרות

$$P(\mathcal{D}|\mu, \sigma^2) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x_n - \mu)^2} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N e^{-\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2}$$

$$L(\mathcal{D}|\mu, \sigma^2) = -N \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2$$

$$\text{Define: } \bar{x} \equiv \frac{1}{N} \sum_{n=1}^N x_n \quad S \equiv \sum_{n=1}^N (x_n - \mu)^2$$

$$L(\mathcal{D}|\mu, \sigma^2) = -N \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} [N(\mu - \bar{x})^2 + S]$$

$$\mu_{ML} = \bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$$
$$\sigma_{ML}^2 = \frac{\sum_{n=1}^N (x_n - \mu_{ML})^2}{N}$$

מימוש בקוד:

```
sum_x=0;
mu_ml=0;
for i= 1:N%%mean ML
    sum_x= sum_x +Xn(i);
end
mu_ml=sum_x/N;
S=0;
for i = 1:N %%S
    S = S + (Xn(i)-mu_ml)^2;
end
L0 = -N*log((var0*2*pi)^0.5) - (N*(mu_ml-mu0)^2+S)/(2*var0);
L1 = -N*log((var1*2*pi)^0.5) - (N*(mu_ml-mul)^2+S)/(2*var1);
```

אחר כך משווים בין שני ה לים רואים לאיזה מהם יש סיכוי יותר גדול.

בשערוך הזה נמצא את התוחלת והשונות ואחר כך נמצא את הנראות, פה יש לנו הסטה בשונות

$$\frac{N-1}{N} \sigma^2$$

(bias)

בגלל שהנחנו שאנחנו לא יודעים את התוחלת והשונות אז כששערכנו את המספר השתמשנו בתוחלת המשעורכת זה מה שגרם ל סטייה, אבל יש לנו Asymptotically unbiased estimator זה אומר כשכל ה N (מספר הדגימות) גדול יותר הסטייה תשאוף לאפס.

חישוב KL divergence:

KL divergence מדד כמה שתי ההתפלגויות שומות אחדת לשניה, במצב שלנו השוני בין ההתפלגות המשוערכת להתפלגות האמיתית. ככל שההבדיל בין ההתפלגויות קטן יותר הערך שמוציאה קטן יותר, בהתחשבות בהסתברות כל קטע בהתפלגות והערך. כלומר כשערך ה KL גדול יותר השוני גדול יותר אז נשתמש בחישוב הזה כמדד כמה הערך שיצא שלנו מדויק לערך האמיתי

החישוב הינו:

$$KL_x(f_1, f_2) = \int f_1(x) \log \frac{f_1(x)}{f_2(x)} dx$$

כאשר f_2 -if1 הינן 2 התפלגויות שנרצה לבדוק את הדמיון ביניהם (התפלגות מקור ומשוערכת).

עבור המקרה הפרטי שלנו, נרצה לבדוק את השוני עבור 2 גאוסיאנים:

$$\begin{aligned} & \int [\log(p(x)) - \log(q(x))] p(x) dx \\ &= \int \left[-\frac{1}{2} \log(2\pi) - \log(\sigma_1) - \frac{1}{2} \left(\frac{x-\mu_1}{\sigma_1} \right)^2 + \frac{1}{2} \log(2\pi) + \log(\sigma_2) + \frac{1}{2} \left(\frac{x-\mu_2}{\sigma_2} \right)^2 \right] \\ & \times \frac{1}{\sqrt{2\pi\sigma_1}} \exp \left[-\frac{1}{2} \left(\frac{x-\mu_1}{\sigma_1} \right)^2 \right] dx \\ &= \int \left\{ \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{1}{2} \left[\left(\frac{x-\mu_2}{\sigma_2} \right)^2 - \left(\frac{x-\mu_1}{\sigma_1} \right)^2 \right] \right\} \times \frac{1}{\sqrt{2\pi\sigma_1}} \exp \left[-\frac{1}{2} \left(\frac{x-\mu_1}{\sigma_1} \right)^2 \right] dx \\ &= E_1 \left\{ \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{1}{2} \left[\left(\frac{x-\mu_2}{\sigma_2} \right)^2 - \left(\frac{x-\mu_1}{\sigma_1} \right)^2 \right] \right\} \\ &= \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{1}{2\sigma_2^2} E_1 \{ (X - \mu_2)^2 \} - \frac{1}{2\sigma_1^2} E_1 \{ (X - \mu_1)^2 \} \\ &= \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{1}{2\sigma_2^2} E_1 \{ (X - \mu_2)^2 \} - \frac{1}{2} \\ & \text{(Now note that)} \\ & (X - \mu_2)^2 = (X - \mu_1 + \mu_1 - \mu_2)^2 = (X - \mu_1)^2 + 2(X - \mu_1)(\mu_1 - \mu_2) + (\mu_1 - \mu_2)^2 \\ &= \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{1}{2\sigma_2^2} [E_1 \{ (X - \mu_1)^2 \} + 2(\mu_1 - \mu_2)E_1 \{ X - \mu_1 \} + (\mu_1 - \mu_2)^2] - \frac{1}{2} \\ &= \log \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2} \end{aligned}$$

אז מה אנחנו רוצים:

$$KL(p, q) = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$$

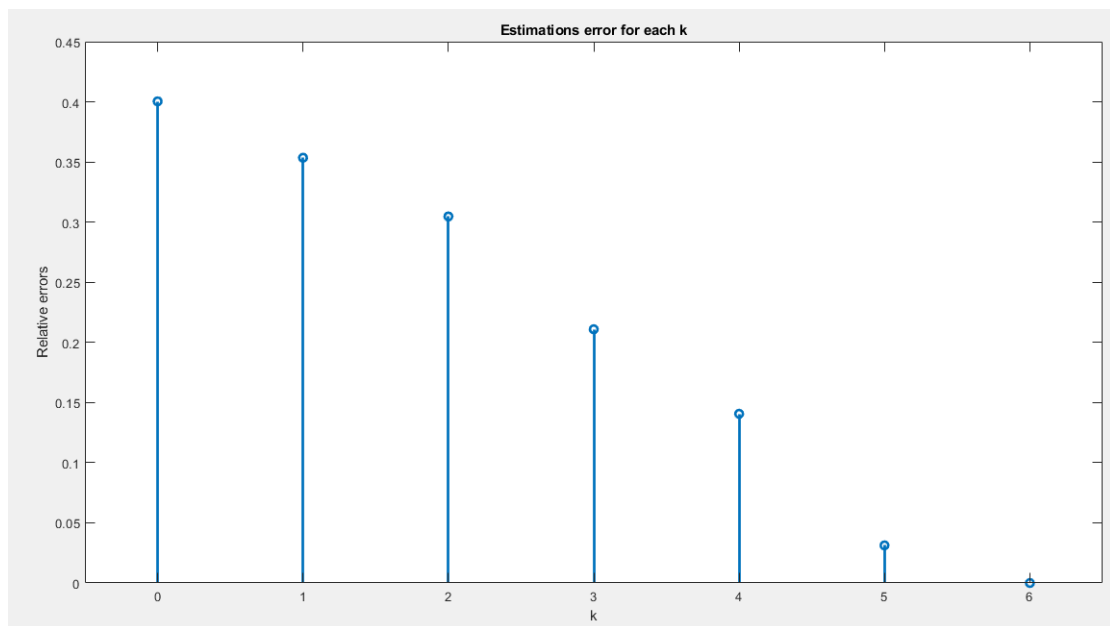
כאשר $\sigma_1 = \sigma_2$, $\mu_1 = \mu_2$ נקבל 0 כלומר ההתפלגויות זהות.

*ההכוחה נמצא באתר הזה:

<https://stats.stackexchange.com/questions/7440/kl-divergence-between-two-univariate-gaussians>

תוצאות הניסוי


שגיאת ה ML ביחס לגודל כל ניסוי



בכל ניסוי מ-0 ל-6 נספרו כמות השגאות בכל שערך של הסדרה D_m ,

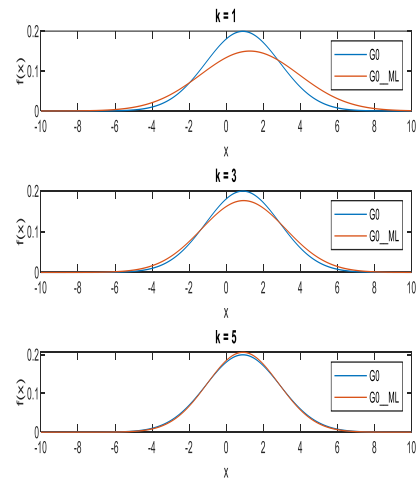
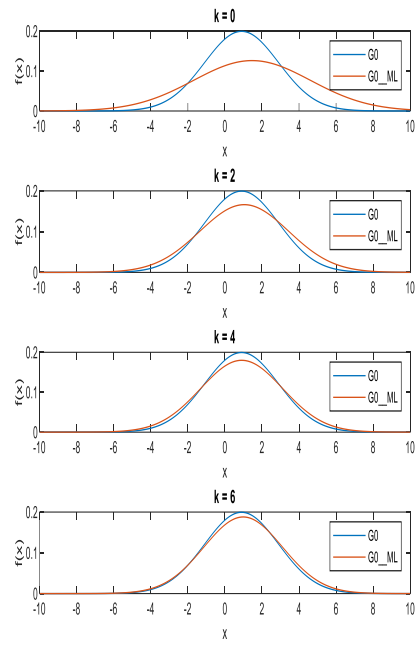
אחרי נירמול כלומר חילוק כמות השגיאות בקמות כל הנסויים יהיה לנו את הגרף למעלה, כפי שרואים אחוז השגיאה הולך וקטן עם הגדלת הסדרה, זה מהסיבה שמשערך ML מתקרב לערך האמיתי עם הגדלת הערכים, גם ההטיה הולכת וקטנת כמו שראינו למעלה.

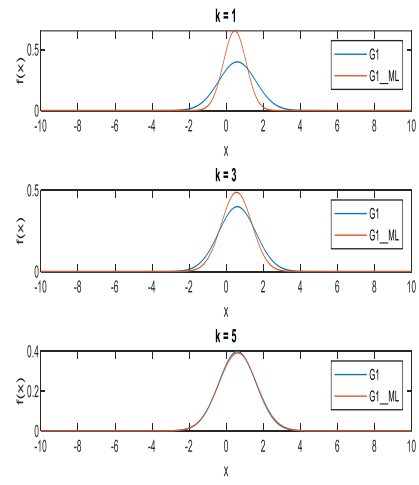
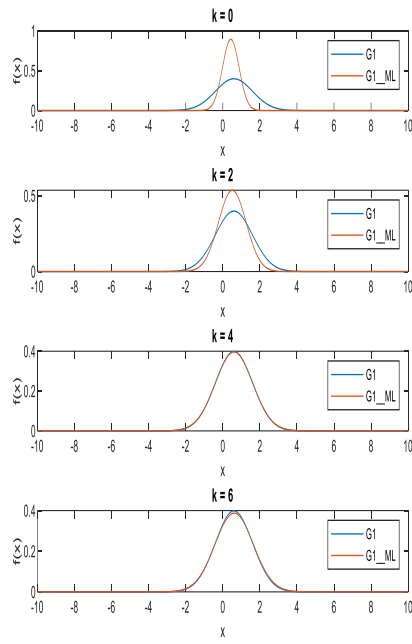
גרף KL:



ככל שאורך הסדרה גדל ערך הKL קטן, מזה נובע שהדמיון בין ההסתברויות הולך וגדל ביחס לאורך השגיאה, וזה מכיוון לסדרה גדולה יש יותר מידע והשערוך נהיה יותר מדויק.

G0:





סיכום ומסקנות

1. שינוי קטן במשוואה נותן תוצאות לא נכונות למשל כמו הוצאת השורש מחוץ לLOG.

זה יכול להיות בגלל שהחישוב יוצא מדויק יותר כשקודם עושים שורש ואחר כך מכפילים

$$L(\mathcal{D}|\mu, \sigma^2) = -N \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} [N(\mu - \bar{x})^2 + S]$$

2. השינוי לא באיברי הסדרה (שזה 1024) אלא כמות תתי הסדרה (DM).

3. ככל שמגדילים כמות המידע התוצאה תהיה יותר מדויקת וזה יושב עם ההגיון של משעריך הML.

4. KL divergence נותן ערך מספרי שבאמצעתו ניתן לדעת עד כמה השערוך היה מדויק. כלומר יכול להיות שזה את הנקודות ששייכים לגוסיאן אבל לא בנה גאוסייאן בצורה נכונה, לכן הוא תלוי בכמות המידע ואיך משתמש בהם.

```

%% Home Work 1
%% yazid bisharat 315914689
%% MAIN %%
clear all;
close all;
clc;
% parameters
mu0 = 0.9; % G0 mean & variance
var0 = 2;
mu1 = 0.6; % G1 mean & variance
var1 = 1;
D = 1024 ; % overall sequence length
k = 0:6 ; % number of experiments(7)
Dm = 2.^k ; % length of Dm with respect to k
m = D./Dm ; % number of sequences Dm

% Init arrays
Gen = zeros(length(k),D); % create matrix of 7x1024, each
row = experiment
failure = zeros(1,length(k)); % fails counter for each k
KL0 = zeros(1,length(k)); % KL for G0 ,for each k
KL1 = zeros(1,length(k)); % KL for G1 ,for each k

for experiment = 1:length(k)
    g0_index = 1;
    g1_index = 1;
    G0_ML=[];
    G1_ML=[];
    for seq = 1:m(experiment) % run on small sequences
        qm = binornd(1,1/2) ; % Bernoulli with p=0.5, every iteration
        get 0 or 1
        % Generation
        if (qm == 0) %Generate subgroup from G0
            Gen(experiment, ((seq-
1)*Dm(experiment)+1):(seq*Dm(experiment))) =
sqrt(var0).*randn(1,Dm(experiment)) + mu0 ;
        else %Generate subgroup from G1
            Gen(experiment, ((seq-
1)*Dm(experiment)+1):(seq*Dm(experiment))) =
sqrt(var1).*randn(1,Dm(experiment)) + mu1 ;
        end

        % ML estimation to determine which Gaussian is Dm
        Xn = Gen(experiment, ((seq-
1)*Dm(experiment)+1):(seq*Dm(experiment)));
        N = length(Xn);
        sum_x=0;
        mu_ml=0;
        for i= 1:N%%mean ML
            sum_x= sum_x +Xn(i);
        end
        mu_ml=sum_x/N;
        S=0;
        for i = 1:N%%S (VARIANCE without norG1_ML
            S = S + (Xn(i)-mu_ml)^2;
        end
        L0 = -N*log((var0*2*pi)^0.5) - (N*(mu_ml-mu0)^2+S)/(2*var0);
        L1 = -N*log((var1*2*pi)^0.5) - (N*(mu_ml-mu1)^2+S)/(2*var1);
        if (L0>L1)

```

```

        qm_est = 0;
        G0_ML(g0_index:g0_index+Dm(experiment)-1) = Xn ;
        g0_index = g0_index + Dm(experiment) ;
    else
        qm_est = 1 ;
        G1_ML(g1_index:g1_index+Dm(experiment)-1) = Xn ;
        g1_index = g1_index + Dm(experiment) ;
    end

    if (qm ~= qm_est)
        failure(experiment) = failure(experiment)+1 ;    % failure
counter
    end

end

% got all subgroups of the current experiment, the features are:
    mu0_est = mean(G0_ML);    var0_est = var(G0_ML);
    mu1_est = mean(G1_ML);    var1_est = var(G1_ML);

% KL calculation for each experiment:
    KL0(experiment) = log(sqrt(var0_est)/sqrt(var0)) + (var0+(mu0-
mu0_est)^2)/(2*var0_est) - 0.5;
    KL1(experiment) = log(sqrt(var1_est)/sqrt(var1)) + (var1+(mu1-
mu1_est)^2)/(2*var1_est) - 0.5;

%%%%%%%%%%%% Plot results:

% G0 & G1
    figure(1)
    x = -10:.1:10;
    subplot(6,2,experiment);
    norm = normpdf(x,mu0,var0);
    plot(x,norm); hold on ;
    norm = normpdf(x,mu0_est,var0_est);
    plot(x,norm);
    str = sprintf('k = %d',experiment-1);
    title(str);
    xlabel('x'); ylabel('f(x)');
    legend('G0','G0__ML');

    figure(2)
    x = -10:.1:10;
    subplot(6,2,experiment);
    norm = normpdf(x,mu1,var1);
    plot(x,norm); hold on ;
    norm = normpdf(x,mu1_est,var1_est);
    plot(x,norm);
    str = sprintf('k = %d',experiment-1);
    title(str);
    xlabel('x'); ylabel('f(x)');
    legend('G1','G1__ML');
end

% Errors in estimation qm:
error_rate = (failure./m );
figure(3)
stem(k,error_rate,'LineWidth',2);

```

```

xlim([-0.5,6.5]);
title('Estimations error for each k');
xlabel('k'); ylabel('Relative errors');

% KL divergence:
figure(4)
stem(k,KL0,'LineWidth',2,'Color','r');
xlim([-0.5,6.5]);hold on;
stem(k+0.1,KL1,'LineWidth',2,'Color','b');
title('Kullback-Leibler values for each k');
xlabel('k'); ylabel('KL divergence'); legend('KL0','KL1');

```